

Como combinar as previsões dos diferentes modelos?

Para combinar previsões de diferentes modelos, usamos a ideia de fusão de classificadores, ou seja, em vez de confiar em apenas um modelo, usamos vários classificadores e juntamos suas respostas para chegar a uma decisão final. Isso é comum em técnicas como Bagging, Random Forest, Boosting e Stacking.

Métodos de votação:

Cada modelo dá sua previsão e o sistema escolhe a resposta final com base nos votos.

Votação majoritária: A classe mais votada vence.

Votação ponderada: Modelos mais confiáveis recebem peso maior. Mesmo que todos votem, os modelos com melhor desempenho influenciam mais a decisão final.

Métodos de seriação:

Não escolhem apenas uma classe diretamente. Eles organizam as possíveis classes em uma ordem de preferência. Depois, o sistema combina esses rankings para descobrir qual classe ficou melhor posicionada no geral.

Métodos estáticos:

A forma de combinar os modelos é definida antes e não muda para cada exemplo, ou seja, o sistema sempre usa a mesma regra. Se o Modelo 1 tem peso 0,8, ele continuará tendo esse peso para todos os casos.

Métodos dinâmicos:

O sistema escolhe ou ajusta os classificadores de acordo com cada caso analisado, ou seja, ele tenta descobrir quais modelos são melhores para aquele exemplo específico.

Explique:

MAI - Model Applicability Induction:

A ideia central é que cada modelo pode ser bom em uma parte diferente dos dados. Então, antes de classificar um novo exemplo, o sistema tenta descobrir qual modelo é mais confiável para aquele caso.

SCANN - Análise de Correspondência Seguida por um Vizinho Mais Próximo:

Possui três partes:

Stacking:

Vários modelos fazem previsões para os exemplos. Essas previsões passam a ser usadas como novas informações para decidir a classe final.

Análise de Correspondência:

É uma técnica estatística usada para encontrar relações entre modelos, previsões de modelos e classes reais. Ela transforma essas relações em um espaço mais organizado, como se fosse um “mapa” das relações entre modelos e classes.

Vizinho Mais Próximo:

Para classificar um novo caso, ele procura exemplos anteriores parecidos e observa como eles foram classificados.

Bootstrap:

É uma técnica de reamostragem de uma base de dados para modelos múltiplos de aprendizagem de máquina. A ideia dela é treinar cada algoritmo com uma base diferente para reduzir o risco do modelo ficar viciado a classificar em uma só classe, então para isso duplica algumas instâncias e remove outras, garantindo que as removidas serão as mesmas para todos os algoritmos criando um conjunto chamado out-of-bag (OOB), é possível utilizar o conjunto OOB para a avaliação do modelo.

Bagging:

Ou em outras palavras, Bootstrap Aggregating é uma técnica de modelos múltiplos. Ela utiliza vários algoritmos preditivos alimentados com uma base de dados modificada pelo Bootstrap e dá como resposta final a classe mais votada/média entre eles.

Boosting:

É uma técnica de modelos múltiplos que treina todos os seus algoritmos em sequência. Conhecido por utilizar apenas modelos fracos, após treinar o primeiro algoritmo ele identifica quais classes ele mais errou e tenta corrigir, mudando os pesos, quando for treinar o próximo. A resposta final é uma votação/média ponderada dos resultados dos algoritmos, pois cada um terá um peso diferente, possui alta precisão, porém com altas chances de ficar enviesado.

Adaboost:

Ou Adaptive Boosting é um algoritmo de modelo múltiplo que utiliza a técnica de Boosting na sua implementação. Quando um algoritmo classifica de forma incorreta uma instância, ele aumenta seu peso.

Random Forest:

É um algoritmo de modelo múltiplo que utiliza a técnica de bagging na sua implementação. Utiliza várias árvores de decisão.

Stacking:

Ou Stacked Generalization é uma técnica de modelo múltiplo que treina um algoritmo para classificar a resposta final ao invés de utilizar a média/votação. Utiliza diferentes algoritmos

para fazer previsões, mas ao invés de ir pela maioria, ela vê padrões de quando alguns algoritmos são mais confiáveis que os outros e os classifica de acordo.